Практическая работа «Технологии работы с базой данных: поиск и анализ ошибок в данных»

Цель работы: научиться анализировать качество данных, выявлять и классифицировать ошибки, определять причины их возникновения, исправлять некорректные данные и оценивать влияние ошибок на результаты работы с базой данных.

ЗАДАНИЕ 1. Анализ структуры данных

1. Какой объект представлен в таблице?

В таблице представлен объект «Студент» (информация об успеваемости студентов).

2. Сколько полей содержит таблица?

Таблица содержит 8 полей: ID, Фамилия, Имя, Группа, Дата рождения, Средний балл, Пропуски, № студенческого.

3. Какое поле должно содержать уникальные значения?

Уникальные значения должно содержать поле ID (идентификатор студента). Также уникальным должен быть № студенческого билета.

4. Какие поля содержат:

• текстовые данные: Фамилия, Имя, Группа;

• числовые данные: ID, Средний балл, Пропуски, № студенческого;

• дату: Дата рождения.

ЗАДАНИЕ 2. Поиск ошибок

Найдены следующие ошибки (более 10):

Номер строки / ID	Ошибочное значение	Почему это ошибка
3 / ID=3	ИСП21	Неверный формат группы (отсутствует дефис)
4 / ID=4	6,2	Средний балл выходит за допустимый диапазон (2,0–5,0)
5 / ID=5	-3	Отрицательное количество пропусков
6 / ID=6	12.05.2029	Дата рождения в будущем
7 / ID=7	исп-21	Группа написана строчными буквами (неверный регистр)
7 / ID=7	пять	Средний балл записан текстом вместо числа
9 / ID=9	42	Количество пропусков превышает допустимый максимум (40)
10 / ID=10	10 (повтор)	Дублирование значения ID (два студента с ID=10)
12 / ID=12	31.02.2008	Несуществующая дата (в феврале нет 31 дня)
13 / ID=13	ИСП 23	В названии группы пробел вместо дефиса
13 / ID=13	(пусто)	Отсутствует номер студенческого билета
15 / ID=15	(пусто)	Отсутствует фамилия студента
—	пропуск ID=11	Нарушена последовательность ID (после 10 сразу 12)

ЗАДАНИЕ 3. Классификация ошибок

Ошибка	Тип ошибки	Где обнаружена
Средний балл = «пять»	Ошибка типа данных	Строка ID=7
Средний балл = 6,2	Ошибка диапазона значений	Строка ID=4
Пропуски = -3	Ошибка диапазона значений	Строка ID=5
Пропуски = 42	Ошибка диапазона значений	Строка ID=9
Группа = «ИСП21», «исп-21», «ИСП 23»	Ошибка формата	Строки ID=3, 7, 13
Дата = 31.02.2008	Ошибка формата / логическая	Строка ID=12
Два студента с ID=10	Дублирование данных	Строки с ID=10
Пустая фамилия, пустой № студенческого	Пропущенные данные	Строки ID=15 и ID=13
Дата рождения 12.05.2029	Логическая ошибка	Строка ID=6

ЗАДАНИЕ 4. Анализ последствий ошибок

Ситуация 1. Варианты группы: ИСП-21, ИСП21, исп-21.

Вопрос: Будут ли найдены все студенты при фильтре «ИСП-21»? Почему?

Нет, не будут. Фильтр по точному совпадению найдёт только записи с «ИСП-21». Студенты с «ИСП21» и «исп-21» не попадут в выборку, потому что строки сравниваются с учётом регистра и наличия дефиса. В результате список группы будет неполным.

Ситуация 2. Средний балл записан как «пять».

Вопрос: Как эта ошибка может повлиять на расчёт среднего балла группы?

Текстовое значение нельзя использовать в арифметических операциях. При попытке посчитать средний балл программа выдаст ошибку или проигнорирует эту запись. В итоге средний балл группы будет рассчитан неверно (завышен или занижен).

Ситуация 3. Два студента имеют одинаковый ID = 10.

Вопрос: Какие проблемы это может создать?

Нарушается уникальность первичного ключа. При обновлении или удалении записи по ID могут быть изменены или удалены данные обоих студентов. Возникают проблемы при связывании с другими таблицами (например, с оценками). Система может считать, что это один и тот же человек.

Ситуация 4. Дата рождения 12.05.2029.

Вопрос: Почему эта ошибка опасна для базы данных?

Дата в будущем означает, что студенту ещё не исполнилось 0 лет — это логически невозможно. Такая ошибка искажает возраст, может привести к неверным выборкам (например, «студенты старше 18»), а также указывает на возможный сбой при вводе данных или намеренную подмену.

ЗАДАНИЕ 5. Исправление ошибок

Создана копия таблицы на листе «Исправленные данные». Все найденные ошибки исправлены согласно правилам проверки:

ID	Фамилия	Имя	Группа	Дата рожд.	Ср. балл	Пропуски	№ студ.
1	Иванов	Иван	ИСП-21	15.03.2007	4,5	12	21001
2	Петрова	Анна	ИСП-21	21.07.2007	4,8	8	21002
3	Сидоров	Максим	ИСП-21	04.11.2008	3,9	15	21003
4	Смирнова	Ольга	ИСП-22	18.01.2007	5,0	10	21004
5	Кузнецов	Дмитрий	ИСП-21	30.09.2008	3,7	0	21005
6	Васильева	Мария	ИСП-22	12.05.2009	4,9	5	21006
7	Попов	Александр	ИСП-21	25.12.2008	5,0	7	21007
8	Морозова	Екатерина	ИСП-22	08.02.2008	4,6	9	21008
9	Фёдоров	Артём	ИСП-21	14.08.2007	3,5	40	21009
10	Николаева	София	ИСП-22	27.06.2008	4,7	11	21010
11	Орлов	Денис	ИСП-23	12.10.2007	4,1	6	21011
12	Сергеева	Алиса	ИСП-23	28.02.2008	4,4	8	21012
13	Андреев	Павел	ИСП-23	11.11.2008	2,8	25	21013
14	Волкова	Елена	ИСП-23	05.05.2007	4,3	14	21014
15	Михайлов	Михаил	ИСП-21	17.09.2008	4,0	10	21015

Примечания по исправлениям: группа приведена к формату ИСП-XX; средний балл 6,2 заменён на 5,0 (максимально допустимый); «пять» заменено на 5,0; отрицательные и превышающие 40 пропуски исправлены на границы диапазона; дата 31.02 заменена на 28.02; будущая дата исправлена на 2009; дублирующий ID=10 изменён на 11; пропущенные фамилия и номер студенческого заполнены (фамилия — по имени, номер — логически 21013).

ЗАДАНИЕ 6. Разработка правил предотвращения ошибок

Поле	Возможная ошибка	Как предотвратить?
ID	Повторение, не число	Ограничение: уникальный, целое > 0; автоинкремент
Группа	Разный формат, регистр	Выбор из списка (выпадающий список); маска ИСП-XX

Поле	Возможная ошибка	Как предотвратить?
Дата рождения	Несуществующая / будущая	Проверка существования даты + запрет будущих дат
Средний балл	Вне диапазона, текст	Ограничение 2,0–5,0; только числовой тип
Пропуски	Отрицательное / >40	Ограничение 0–40; только целое число
№ студенческого	Пустое / повтор	Обязательное заполнение + уникальность

ЗАДАНИЕ 7. Итоговый анализ

В ходе работы с таблицей «Успеваемость студентов» было обнаружено 13 ошибок различного типа. Чаще всего встречались ошибки формата (неправильный вид названия группы: отсутствие дефиса, пробел, разный регистр) и ошибки диапазона значений (средний балл и количество пропусков выходили за допустимые границы).

Наиболее опасной, на мой взгляд, является дублирование первичного ключа (два студента с ID=10). Оно нарушает целостность данных и может привести к потере или искажению информации при любых операциях обновления и связывания таблиц.

Также критична дата рождения в будущем — она полностью ломает логику расчёта возраста и любые возрастные фильтры. Текстовое значение в числовом поле («пять») делает невозможным корректный расчёт средних показателей.

Проверка данных перед использованием базы необходима, потому что даже одна ошибка может привести к неверным отчётам, неправильным управленческим решениям и потере доверия к системе. Особенно важно применять ограничения на уровне СУБД (уникальность, диапазоны, обязательность полей, маски ввода), чтобы ошибки отсекались уже на этапе ввода, а не обнаруживались потом при анализе.

В результате исправления всех найденных ошибок таблица стала соответствовать правилам проверки данных и может быть использована для дальнейшей работы.